Import et traitement des données pour le projet Graphe (Neo4j / Cypher)

Ce document résume les choix méthodologiques effectués pour le traitement, la sélection et l'import des données utilisées dans le projet. L'objectif principal est de permettre l'écriture de requêtes de chemins expressives tout en évitant les problèmes de performance et de timeouts mis en évidence dans les articles étudiés.

1. Principe général

Les données sont traitées en amont à l'aide d'un script Python avant leur import dans Neo4j. Ce choix permet de : - réduire la complexité des requêtes Cypher, - éviter des calculs imbriqués coûteux, - travailler sur une échelle temporelle unique (UTC), - faciliter l'expression de contraintes sur les chemins.

2. Sélection et préparation des données

Trois sources de données sont utilisées : - Airports : informations géographiques et temporelles des aéroports, - Flights : informations sur les vols, - Airlines : dictionnaire des compagnies aériennes.

3. Traitement temporel (Flights)

Les données temporelles brutes contiennent plusieurs variables redondantes. Afin d'éviter toute ambiguïté, quatre timestamps UTC sont construits : - départ prévu (UTC), - départ réel (UTC), - arrivée prévue (UTC), - arrivée réelle (UTC). Les variables intermédiaires (hour, minute, time_hour, sched_dep_time, dep_time) sont ensuite supprimées.

4. Rôle des fuseaux horaires

Les variables tz, dst et tzone sont conservées au niveau des aéroports. Elles servent à restreindre l'espace de recherche en définissant des sous-graphes logiques, mais ne sont pas utilisées pour les calculs temporels.

5. Modélisation graphe retenue

- Les aéroports sont modélisés comme des nœuds Airport. - Les vols sont modélisés comme des relations FLIGHT entre aéroports. - Les compagnies aériennes sont intégrées comme propriétés des relations.

6. Import dans Neo4j

Les fichiers CSV issus du pré-traitement sont importés via LOAD CSV. Les relations FLIGHT contiennent les propriétés numériques et temporelles nécessaires à l'écriture de requêtes de chemins complexes.

7. Objectif de ces choix

Ces choix permettent de : - mettre en évidence les limites de Cypher 5, - illustrer les problèmes du traitement de listes, - montrer l'apport de Cypher 25 pour l'expressivité et la performance.